

Raport WdAD

Aneta Buszta, Klaudia Czarny, Wioletta Sudoł

June 2025

1 Opis zbioru danych

Źródło danych

W celu przeprowadzenia analizy wybrałyśmy zbiór danych *Predict Students' Dropout and Academic Success*, dostępny na platformie Kaggle. Zbiór zawiera informacje dotyczące 4424 studentów i został opracowany przez zespół badawczy Politechniki Portalegre w Portugalii. Stanowi on solidną podstawę do eksploracji danych, budowy modeli predykcyjnych oraz wyciągania praktycznych wniosków.

Atrybuty

Zbiór danych zawiera 37 czynników, które potencjalnie mogą wpływać na analizowany wynik. W naszych rozważaniach pomijamy jednak kolumny „GDP” oraz „Inflation rate”, ponieważ nie mają one istotnego wpływu na rezultat analizy.

- Marital status – Stan cywilny
- Application mode – Tryb składania podania
- Application order – Kolejność składania podania
- Course – Kierunek studiów
- Daytime/evening attendance – Uczęszczanie na zajęcia dzienne/zaoczne
- Previous qualification – Poprzednie kwalifikacje
- Previous qualification (grade) – Ocena poprzednich kwalifikacji
- Nationality – Narodowość
- Mother's qualification – Kwalifikacje matki
- Father's qualification – Kwalifikacje ojca
- Mother's occupation – Zawód matki
- Father's occupation – Zawód ojca
- Admission grade – Ocena przyjęcia (wynik rekrutacji)
- Displaced – Osoba przesiedlona
- Educational special need – Specjalne potrzeby edukacyjne
- Debtor – Osoba zalegająca z opłatami
- Tuition fees up to date – Opłaty czesnego uregulowane na bieżąco
- Gender – Płeć

- Scholarship holder – Stypendysta
- Age at enrollment – Wiek podczas zapisu na studia
- International – Student międzynarodowy
- Curricular units 1st sem (credited) – Liczba przepisanych jednostek programowych 1. semestru
- Curricular units 1st sem (enrolled) – Liczba zapisów na jednostki programowe 1. semestru
- Curricular units 1st sem (evaluations) – Liczba ocen za jednostki programowe 1. semestru
- Curricular units 1st sem (approved) – Liczba zaliczonych jednostek programowych 1. semestru
- Curricular units 1st sem (grade) – Średnia ocen z jednostek programowych 1. semestru
- Curricular units 1st sem (without evaluations) – Liczba jednostek programowych 1. semestru bez ocen
- Curricular units 2nd sem (credited) – Liczba przepisanych jednostek programowych 2. semestru
- Curricular units 2nd sem (enrolled) – Liczba zapisów na jednostki programowe 2. semestru
- Curricular units 2nd sem (evaluations) – Liczba ocen za jednostki programowe 2. semestru
- Curricular units 2nd sem (approved) – Liczba zaliczonych jednostek programowych 2. semestru
- Curricular units 2nd sem (grade) – Średnia ocen z jednostek programowych 2. semestru
- Curricular units 2nd sem (without evaluations) – Liczba jednostek programowych 2. semestru bez ocen
- Unemployment rate – Wskaźnik bezrobocia
- Target – Zmienna docelowa (np. rezygnacja ze studiów)

2 Cel analizy

- **Cel biznesowy:**
Identyfikacja kluczowych czynników wpływających na sukces akademicki studentów, co może przyczynić się do opracowania lepszych metod wsparcia.
- **Cel analityczny:**
Zbudowanie i porównanie modeli klasyfikacyjnych: KNN, drzew decyzyjnych (C5.0) oraz naiwnych klasyfikatorów Bayesa, aby określić, który z nich najlepiej przewiduje końcową decyzję studenta.

3 Uzasadnienie wyboru zastosowanych narzędzi analizy danych

W celu przeprowadzenia analizy predykcyjnej dotyczącej rezygnacji studentów ze studiów zdecydowaliśmy się na zastosowanie trzech klasycznych algorytmów klasyfikacyjnych: K-Nearest Neighbors (KNN), drzew decyzyjnych (C5.0) oraz Naive Bayes.

- **KNN (K-Nearest Neighbors):** metoda ta została wybrana ze względu na swoją prostotę, brak potrzeby budowania skomplikowanego modelu oraz dobrą skuteczność przy danych, które nie wymagają silnych założeń co do rozkładu zmiennych. W zbiorze danych występuje wiele zmiennych numerycznych, które mogą mieć różną skalę.
- **Drzewa decyzyjne (C5.0):** wybrane zostały ze względu na to, że, pozwalają one nie tylko na klasyfikację, ale także na ocenę znaczenia poszczególnych zmiennych w podejmowaniu decyzji. Jest to szczególnie istotne w kontekście edukacyjnym, gdzie istotne jest zrozumienie czynników wpływających na rezygnację ze studiów.
- **Naive Bayes:** metoda probabilistyczna, która została uwzględniona ze względu na szybkość działania i wysoką skuteczność w analizie danych kategorycznych, których w zbiorze jest bardzo dużo (np. płeć, forma studiowania, status stypendialny).

4 Specyfikacja zastosowanych modeli analitycznych

Metoda najbliższych sąsiadów (KNN)

- Podział danych na zbiór treningowy (80%) i testowy (20%).
- Standaryzacja danych (z-score) dla kolumn numerycznych.

- Przeprowadzenie klasyfikacji na danych standaryzowanych.
- Optymalizacja parametru k przez testowanie wartości od 1 do 50 i wybór najlepszego wyniku dokładności.

Drzewa decyzyjne (C5.0)

- Konwersja wybranych zmiennych jakościowych na typ **factor**.
- Podział danych na zbiór treningowy i testowy.
- Budowa klasyfikatora drzewa decyzyjnego C5.0.
- Ocena modelu i predykcja na zbiorze testowym.
- Zastosowanie wzmocnienia adaptacyjnego (boosting) z parametrem **trials** = 10 w celu poprawy dokładności.

Naiwny klasyfikator Bayesa (Naive Bayes)

- Trening modelu Naive Bayes na danych kategoriycznych.
- Predykcja klasy na zbiorze testowym.
- Obliczenie dokładności klasyfikatora.
- Zastosowanie estymatora Laplace'a (**laplace** = 1) w celu poprawy rozkładu prawdopodobieństw i zwiększenia skuteczności klasyfikacji.

5 Opis weryfikacji jakości zbudowanych modeli

5.1 K-NN

Dane podzielono na zbiór treningowy i testowy oraz poddano standaryzacji, aby zapewnić równy wpływ cech na obliczenia odległości.

- **Model 1**
Klasyfikacja KNN dla losowo wybranej liczby: $k = 5$

	Actual			
Predicted	Dropout	Enrolled	Graduate	Row Total
Dropout	197	31	19	247
	0.223	0.035	0.021	
Enrolled	43	35	32	110
	0.049	0.040	0.036	
Graduate	65	90	373	528

	0.073	0.102	0.421	
Column Total	305	156	424	885

Otrzymujemy dokładność na poziomie 0.6836

- **Model 2**

Testowanie różnych wartości k wykazało, że najlepszą dokładność uzyskano przy $k = 13$.

```
[1] "k = 1 Accuracy = 0.64180790960452"
[1] "k = 2 Accuracy = 0.618079096045198"
[1] "k = 3 Accuracy = 0.67683615819209"
[1] "k = 4 Accuracy = 0.690395480225989"
[1] "k = 5 Accuracy = 0.68361581920904"
[1] "k = 6 Accuracy = 0.67909604519774"
[1] "k = 7 Accuracy = 0.701694915254237"
[1] "k = 8 Accuracy = 0.692655367231638"
[1] "k = 9 Accuracy = 0.694915254237288"
[1] "k = 10 Accuracy = 0.696045197740113"
[1] "k = 11 Accuracy = 0.693785310734463"
[1] "k = 12 Accuracy = 0.703954802259887"
[1] "k = 13 Accuracy = 0.709604519774011"
```

Wartości k bliskie 13 cechują się podobną dokładnością

```
[1] "k = 14 Accuracy = 0.702824858757062"
[1] "k = 15 Accuracy = 0.706214689265537"
[1] "k = 16 Accuracy = 0.703954802259887"
[1] "k = 17 Accuracy = 0.703954802259887"
[1] "k = 18 Accuracy = 0.708474576271186"
[1] "k = 19 Accuracy = 0.706214689265537"
[1] "k = 20 Accuracy = 0.697175141242938"
[1] "k = 21 Accuracy = 0.702824858757062"
[1] "k = 22 Accuracy = 0.700564971751412"
[1] "k = 23 Accuracy = 0.700564971751412"
[1] "k = 24 Accuracy = 0.705084745762712"
[1] "k = 25 Accuracy = 0.699435028248588"
```

Testowanie różnych wartości k pokazało, że model jest stabilny i niezbyt wrażliwy na małe zmiany tego parametru. Osiągnęliśmy dokładność ponad 70 % co jest dobrym wynikiem przy trzech klasach i stosunkowo złożonym zbiorze danych (Dropout, Enrolled, Graduate).

5.2 Drzewa decyzyjne

Dane zostały podzielone na zbiór treningowy i testowy, a zmienne kategoryczne przekształcono do typu factor, co umożliwiło poprawne działanie modelu.

- **Model 1**

Model drzewa decyzyjnego osiągnął dokładność 0.7322

Predicted	Actual			Row Total
	Dropout	Enrolled	Graduate	
Dropout	221 0.250	42 0.047	16 0.018	279
Enrolled	32 0.036	47 0.053	28 0.032	107
Graduate	52 0.059	67 0.076	380 0.429	499
Column Total	305	156	424	885

- **Model 2**

Wzmocniony model drzewa decyzyjnego (C5.0) osiągnął dokładność 0.7514

Predicted	Actual			Row Total
	Dropout	Enrolled	Graduate	
Dropout	226 0.255	32 0.036	12 0.014	270
Enrolled	29 0.033	58 0.066	31 0.035	118
Graduate	50 0.056	66 0.075	381 0.431	497
Column Total	305	156	424	885

W klasyfikacji studentów na trzy grupy (Dropout, Enrolled, Graduate) algorytm drzew decyzyjnych C5.0 osiągnął umiarkowaną skuteczność. Model podstawowy uzyskał dokładność 73,22 % natomiast zastosowanie wzmocnienia adaptacyjnego (boosting) poprawiło wynik do 75,14 % . Zastosowanie boostingu pozwoliło lepiej rozróżnić klasy, zwłaszcza poprawiając trafność dla klasy Enrolled, co wskazuje na korzyści z jego użycia przy bardziej złożonych danych.

5.3 Naive Bayes

Dane zostały podzielone na zbiór treningowy i testowy, a zmienne katagoryczne przekształcono do typu `factor`, co umożliwiło poprawne działanie modelu.

- **Model 1**

Osiągnęliśmy dokładność na poziomie 0.6937

Predicted	Actual			Row Total
	Dropout	Enrolled	Graduate	
Dropout	183 0.207	26 0.029	21 0.024	230
Enrolled	75 0.085	74 0.084	46 0.052	195
Graduate	47 0.053	56 0.063	357 0.403	460
Column Total	305	156	424	885

- **Model 2**

Model z wykorzystaniem estymatora Laplace'a osiągnął dokładność na poziomie 0.6881

Predicted	Actual			Row Total
	Dropout	Enrolled	Graduate	
Dropout	183 0.207	26 0.029	21 0.024	230
Enrolled	74 0.084	71 0.080	48 0.054	193
Graduate	48 0.054	59 0.067	355 0.401	462
Column Total	305	156	424	885

W klasyfikacji studentów na trzy grupy (Dropout, Enrolled, Graduate) algorytm Naive Bayes uzyskał dokładność 69,38 % . Zastosowanie wygładzania Laplace'a nie przyniosło istotnej poprawy skuteczności, co sugeruje, że model ten ma ograniczoną zdolność rozróżniania klas w przypadku bardziej złożonych danych katagorycznych.

6 Podsumowanie

Przeprowadzona analiza danych i klasyfikacja studentów wykazała, że zarówno algorytm KNN, jak i drzewa decyzyjne C5.0 są skutecznymi metodami w zadaniu przewidywania statusu studenta. KNN po standaryzacji danych osiągnął dokładność przekraczającą 70 % . Z kolei drzewa decyzyjne C5.0, szczególnie w wersji wzmocnionej, pozwoliły na jeszcze lepsze rozróżnienie klas i osiągnęły najwyższą skuteczność wśród testowanych modeli. Metoda Naive Bayes wypadła nieco słabiej, a dodanie wygładzania Laplace'a nie wpłynęło istotnie na poprawę wyników. Mimo to, wszystkie zastosowane algorytmy umożliwiły skuteczną klasyfikację i porównanie różnych podejść do problemu przewidywania dalszych losów studentów na podstawie danych edukacyjnych i społecznych.